Homework 2 - LIF Neuron Simulation and SNN Exploration

> 主题：LIF神经元动力学仿真与脉冲编码分析，脉冲编码机制与SNN的适用场景探索

Section 1 LIF Neuron Simulation （50分）

Part 1. Objectives — 实验目标

本次作业要求使用 Python 实现一个 Leaky Integrate-and-Fire（LIF）神经元模型，通过可视化和参数实验，理解神经元膜电位的积分、泄漏、阈值发放与重置机制，以及输入信号如何影响神经元的脉冲发放频率和时间分布。

Part 2. Implementation — 模型实现（20分）

Task 1. 实现 LIF 神经元模型（10分）

根据课堂介绍的 LIF 模型：

$$\tau_m \frac{dV(t)}{dt} = -(V(t) - V_{\text{rest}}) + RI(t)$$

使用 Euler 方法进行离散化，实现膜电位更新：

$$V_{t+\Delta t} = V_t + \frac{\Delta t}{\tau_m}[-(V_t - V_{\text{rest}}) + RI_t]$$

当膜电位达到发放阈值时，记录一次 Spike，并将膜电位重置为 V_{reset}。

程序应正确实现：

- 膜电位积分（Integration）与泄漏（Leak）。
- 阈值检测与脉冲发放（Threshold & Spike）。
- 膜电位重置（Reset）。
- 不应期（Refractory Period）。

推荐初始参数如下，可根据实际实验调整：

Parameter	Initial Value
Resting potential (V_{rest})	-65 mV
Reset potential (V_{reset})	-65 mV
Firing threshold (V_{th})	-50 mV
Membrane time constant (τ_m)	20 ms
Membrane resistance (R)	10 MΩ
Refractory period	2 ms

Parameter	Initial Value
Time step (Δt)	0.1 ms
Simulation duration (T)	2000 ms

Task 2. 输入电流与可视化（10分）

单人完成的请至少实现一种输入，多人小组请至少实现两种输入：

1. Constant Input

$$I(t) = I_0$$

2. Periodic Input

$$I(t) = I_0 + A\cos(2\pi ft + \phi)$$

其中，(I_0) 表示基础电流，(A) 表示振幅，(f) 表示频率，(ϕ) 表示相位。可尝试 $I_0 = 2nA$、$A = 0.8nA$、$f = 5Hz$。

要求在同一可视化界面中展示以下四种信号：

1. **Input Current ($I(t)$)**：输入电流随时间变化。
2. **Membrane Potential ($V(t)$)**：膜电位随时间变化，标出发放阈值。
3. **Spike Train ($S(t)$)**：使用竖线或 Raster Plot 表示脉冲的发生时刻。
4. **Firing Rate ($r(t)$)**：使用滑动时间窗口或核平滑方法估计随时间变化的发放率，单位为 Hz。

可以考虑使用 `matplotlib.widgets.Slider` 实现交互式参数调节，至少支持修改输入电流强度、阈值和膜时间常数。也可以使用任何你喜欢的其他 Python 可视化工具。

注意： Firing Rate 应根据实际检测到的 Spike 计算，而不是直接将输入电流或膜电位作为发放率。

Part 3. Experiments — 对照实验（30分）

在完成模型后，开展以下实验。每组实验应遵循控制变量原则，并保存对应的可视化结果。

Experiment 1. Effect of Firing Threshold（10分）

固定输入电流和其他参数，至少选择三个不同的发放阈值（例如 -55、-50、-45 mV），观察：

- 膜电位达到阈值所需的时间如何改变?
- Spike 数量及平均 Firing Rate 如何变化?
- 在哪些条件下神经元可能不产生 Spike?

Experiment 2. Effect of Input Current（10分）

固定其他参数，逐步改变恒定输入电流的强度，例如1.0、1.5、2.0、$2.5nA$。

观察并分析：

- 是否存在神经元由不发放转变为持续发放的临界输入?
- 输入电流增强时，Spike 间隔如何改变?

- 平均 Firing Rate 是否呈线性变化？为什么？

Experiment 3. Effect of Membrane Time Constant（10分）

分别设置 $\tau_m = 10, 20, 40ms$，在相同输入和其他固定参数下比较：

- 膜电位积分与泄漏的时间尺度如何改变？
- 膜电位曲线、首个 Spike 时间及发放频率有何差异？
- 从膜电路的角度解释 (τ_m) 的物理意义。

各实验至少记录 Spike 总数及平均 Firing Rate，建议使用表格汇总。

Part 4. Bonus — 扩展任务

注意：单人完成的同学本项选做。按小组完成的同学需完成至少一项才可获得满分！！

选择以下任意一项完成：

Option A — Synaptic Current（5分）

进一步实现指数衰减突触电流，模拟离散突触输入事件，比较其与恒定电流输入下的膜电位响应。

Option B — Spike Encoding（5分）

设计两组具有近似相同平均 Firing Rate、但 Spike 时间分布不同的输入或输出序列。使用 Raster Plot 展示差异，并讨论 Rate Coding 与 Temporal Coding 的信息表达特点。

Option C — PFM vs LIF（5分）

额外实现一个简单的 Pulse Frequency Modulation（PFM）模型，比较其与 LIF 模型在积分、阈值发放以及泄漏机制上的异同。

Section 2 LIF Neuron Simulation

Part 1. Objectives — 实验目标

在上一节课中，我们已经实现了基于 Spiking Neural Network（SNN）的 MNIST 手写数字分类。本次作业将进一步探索 SNN 的输入编码机制及其对网络性能的影响，并思考 SNN 在哪些任务和数据类型中可能具有独特优势。

Part 2. Exploration — 模型探索（50分）

Task 1 — Exploring Different Spike Encoding Methods（10分）

任务目标：理解不同 Spike Encoding 方法如何将静态视觉信息转换为脉冲序列。

请基于 MNIST 数据集，分别实现以下三种 Spike Encoding 方法：

1. **Rate Coding**：通过神经元在一定时间窗口内的发放频率表示像素强度。
2. **Latency Coding**：通过神经元的首次发放时间表示像素强度。
3. **Self-selected Coding**：自行调研并选择另一种 Spike Encoding 方法（例如 Phase Coding、Rank-order Coding、Population Coding 等），也可以在已有方法基础上进行适当改进。

实验要求：

1. 简述三种编码方式的基本原理，并给出相应的数学表达式或算法流程。
2. 选择相同的 MNIST 图像，分别使用三种方法编码为 Spike Train。
3. 绘制并比较三种编码方式的 **Input Spike Raster**，展示不同时间步下神经元的发放情况。
4. 统计三种编码方式的 Spike 数量或平均发放率，分析其稀疏性与时间分布特征。

思考问题：

- 不同编码方式分别通过 Spike 的什么特征表示原始信息？
- 哪些编码方式更依赖时间精度？哪些更依赖发放数量？
- 对于不包含真实时间信息的静态图像，将其编码为 Spike Train 可能带来哪些收益与额外成本？

Task 2 — Evaluating Spike Encoding in SNNs（20分）

任务目标：研究不同编码方法及时间步数量对 SNN 分类性能和计算活动的影响。

沿用上一节课的 MNIST 分类任务，保持相同的 SNN 网络架构，分别使用 Task 1 中实现的三种编码方式作为输入，训练并评估相应的 SNN。

实验要求：

1. 使用相同的 SNN 网络结构、数据集划分和训练策略，分别测试三种编码方式。
2. 对每种编码方式设置不同的时间步数量，例如：$T \in \{10, 20, 50, 100\}$
3. 至少记录并比较以下指标：
    - **Classification Accuracy**：测试集分类准确率。
    - **Spike Count / Firing Rate**：输入层和至少一个隐藏层的脉冲数量或平均发放率。
    - **Inference Time**：模型完成一次前向推理所需的时间。
4. 绘制相关实验曲线或对比图，例如：
    - Accuracy vs. Time Steps
    - Spike Count vs. Time Steps
    - Accuracy vs. Spike Count
5. 根据实验结果分析不同编码方式的优势、局限及适用条件。

实验注意事项：

- 应尽可能控制网络架构、参数量、训练轮数及其他实验条件，确保对比的公平性。
- 记录硬件与软件环境，保证实验可复现。
- 推理时间应在相同设备与批量大小下测量，并进行多次重复取平均值。
- Spike Count 可以用于分析网络活动稀疏性，但不能直接等同于硬件能耗。

思考问题：

- 不同编码方式对 SNN 的分类性能是否具有显著影响？为什么？
- 增加时间步是否一定能够提高准确率？可能付出哪些代价？
- Spike 数量更少，是否一定意味着计算效率更高？
- 对于静态视觉任务，是否存在一种编码方式能够同时兼顾准确率、低延迟与稀疏性？

Task 3 — Exploring Where SNNs May Have Advantages（20分）

任务目标：跳出传统静态图像分类任务，探索 SNN 更有可能发挥优势的数据类型与应用场景。

SNN 具有时间动力学和基于脉冲事件的信息处理机制。然而，在传统视觉任务中，将静态图像转换为 Spike Train 是否具有必要性，仍值得讨论。

本任务要求同学们自行调研一个可能更适合 SNN 的数据集，分析其数据特征，并完成基础实验。

Part A — Dataset Exploration（10分）

自行寻找一个具有时间结构或事件驱动特征的公开数据集。

可考虑但不限于：

- **Event-based Vision**：基于事件相机的视觉数据，例如 N-MNIST、DVS Gesture。
- **Neuromorphic Auditory Data**：具有脉冲或事件形式的声音数据，例如 SHD（Spiking Heidelberg Digits）。
- **Time-series / Sensor Data**：具有明显时间依赖的传感器、动作或其他序列数据。

要求简要介绍：

1. 数据集名称、来源与任务目标。
2. 数据格式、规模和主要特征。
3. 数据是否天然包含时间或事件信息，是否需要额外转换为 Spike。
4. 为什么认为该数据集可能适合 SNN？其潜在优势是什么？

Part B — Basic Implementation（10分）

注意：单人完成的同学本项选做。按小组完成的同学必须完成本项才可获得满分！！

基于所选数据集，完成一个简单的探索性实验：

1. 加载部分数据并进行可视化，展示其中的时间或事件信息。
2. 使用一个基础 SNN 模型完成初步的分类、预测或其他相关任务。

   可以参考公开实现，并根据计算资源适当缩小数据规模或网络结构。
3. 展示至少一项实验结果，例如分类准确率、Spike Raster、时间窗口对性能的影响等。

本部分不要求达到较高性能，也不要求实现复杂网络，重点在于理解数据特征与 SNN 计算机制之间的联系。

Submission — 提交要求

1. 当堂讨论2026-11-16：准备好PPT或任意你认为方便的讨论形式，需要在课堂上展示作业结果及讨论内容
2. 提交要求：
   - 内容：PDF格式报告（结果以及简要文字说明）+代码，打包为zip文件
   - 截止日期：2026-11-23 23:59
   - 文件命名：[姓名]-[学号]-Homework2.zip
   - 提交方式待定